

Introduction, or how the brain works?

يتضمن التعلم الآلي آليات تمكن أجهزة الكمبيوتر من التعلم من التجربة والتعلم بالقوة والتعلم عن طريق القياس. يمكن أن تحسن قدرات التعلم أداء النظام الذكي بمرور الوقت. أكثر الأساليب شيوعاً للتعلم الآلي هي الشبكات العصبية الاصطناعية والخوارزميات الجينية الشبكات العصبية:


يمكن تعريف الشبكة العصبية على أنها نموذج للتفكير يعتمد على العقل البشري. يتكون الدماغ من مجموعة كثيفة الترابط من الخلايا العصبية ، أو وحدات معالجة المعلومات الأساسية ، تسمى الخلايا العصبية .

يشتمل الدماغ البشري على ما يقرب من 10 مليارات خلية عصبية و 60 تريليون وصلة ونقاط تشابك كهربائية فيما بينها. باستخدام خلايا عصبية متعددة في وقت واحد ، يمكن للدماغ أداء وظائفه بشكل أسرع بكثير من أسرع أجهزة الكمبيوتر الموجودة اليوم

كل خلية عصبية لها بنية بسيطة للغاية ، لكن جيشاً من هذه العناصر يشكل قوة معالجة هائلة .

يتكون العصبون من جسم الخلية ، سوما soma ، وعدد من الألياف تسمى التشعبات dendrites ، وقطعة واحدة طويلة تسمى المحور العصبي axon.

Biological neural network



يمكن اعتبار دماغنا نظام معالجة معلومات معقد للغاية وغير خطي ومتوازي


يتم تخزين المعلومات ومعالجتها في شبكة عصبية في وقت واحد عبر الشبكة بأكملها،

التعلم هو خاصية أساسية وأساسية للشبكات العصبية البيولوجية. أدت السهولة التي يمكنهم بها التعلم إلى محاولات محاكاة شبكة عصبية بيولوجية في الكمبيوتر.

الشبكة العصبية الاصطناعية:

تتكون الشبكة العصبية الاصطناعية من عدد من المعالجات البسيطة جداً processors ، والتي تسمى أيضاً الخلايا العصبية neurons ، والتي تشبه الخلايا العصبية البيولوجية في الدماغ . ترتبط الخلايا العصبية بواسطة روابط موزونة تمرر إشارات من خلية عصبية إلى أخرى . يتم إرسال إشارة الخرج من خلال الاتصال الخارج للخلايا العصبية . ينقسم الاتصال الصادر إلى عدد من الفروع التي ترسل نفس الإشارة . تنتهي الفروع الصادرة عند الاتصالات الواردة للخلايا العصبية الأخرى في الشبكة .

Architecture of a typical artificial neural network:




التشابه بين الشبكة العصبية البيولوجية والاصطناعية

Biological Neural Network	Artificial Neural Network
Soma	Neuron
Dendrite	Input
Axon	Output
Synapse	Weight

The neuron as a simple computing element

Diagram of a neuron



تحتسب الخلايا العصبية المجموع المرجح لإشارات الإدخال وتقارن النتيجة بقيمة عتبة threshold value θ ، إذا كان صافي الإدخال أقل من العتبة θ ، يكون ناتج العصبون -1 . ولكن إذا كان صافي الإدخال أكبر من أو يساوي الحد الأدنى θ ، يتم تنشيط الخلية العصبية ويصل ناتجها إلى قيمة $+1$.

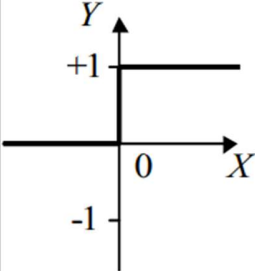
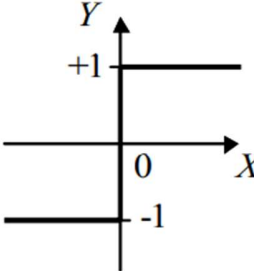
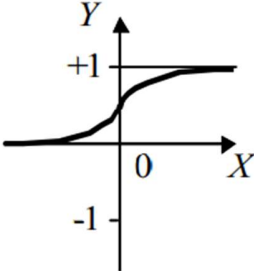
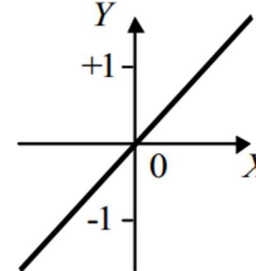
تستخدم الخلايا العصبية وظيفة النقل أو التنشيط التالية:

$$X = \sum_{i=1}^n x_i w_i$$

$$Y = \begin{cases} +1, & \text{if } X \geq \theta \\ -1, & \text{if } X < \theta \end{cases}$$

يسمى هذا النوع من دالة التنشيط دالة الإشارة.

Activation functions of a neuron

Step function	Sign function	Sigmoid function	Linear function
			
$Y^{step} = \begin{cases} 1, & \text{if } X \geq 0 \\ 0, & \text{if } X < 0 \end{cases}$	$Y^{sign} = \begin{cases} +1, & \text{if } X \geq 0 \\ -1, & \text{if } X < 0 \end{cases}$	$Y^{sigmoid} = \frac{1}{1+e^{-X}}$	$Y^{linear} = X$


Can a single neuron learn a task?

Perceptron:

خوارزمية تدريب قدمت الإجراء الأول لتدريب ANN البسيط:

perceptron هو أبسط شكل من أشكال الشبكة العصبية. يتكون من خلية عصبية واحدة ذات أوزان متشابهة قابلة للتعديل ومحدد صلب hard limiter

Single-layer two-input perceptron



يعتمد تشغيل نظام إدراك Rosenblatt على نموذج الخلايا العصبية McCulloch و Pitts. يتكون النموذج من مُدمج خطي متبوعاً بمحدد ثابت


يتم تطبيق المجموع المرجح للمدخلات على المحدد الثابت ، والذي ينتج عنه مخرجات تساوي +1 إذا كان الإدخال موجباً و -1 إذا كان سالباً.

الهدف من perceptron هو تصنيف المدخلات ، x_1 ، x_2 ، ... ، x_n ، في صف أو صفين ، على سبيل المثال A_1 و A_2 .


■ في حالة perceptron ، يتم تقسيم الفضاء ذي البعد n بواسطة المستوى الفائق إلى منطقتان قرار . يتم تحديد المستوى الفائق **hyperplane** بواسطة الدالة القابلة للفصل خطياً **the linearly separable function**.

$$\sum_{i=1}^n x_i w_i - \theta = 0$$

Linear separability in the perceptrons:



(a) Two-input perceptron.



(b) Three-input perceptron.

How does the perceptron learn its classification tasks?

يتم ذلك عن طريق إجراء تعديلات صغيرة في الأوزان لتقليل الفرق بين المخرجات الفعلية والمرغوبة perceptron. يتم تعيين الأوزان الأولية بشكل عشوائي ، عادةً في النطاق $[-0.5, +0.5]$ ، ثم يتم تحديثها للحصول على المخرجات المتوافقة مع أمثلة التدريب.

إذا كان الناتج الفعلي عند التكرار p هو $Y(p)$ وكان الناتج المطلوب $Y_d(p)$ ، فسيتم إعطاء الخطأ بواسطة:

$$e(p) = Y_d(p) - Y(p)$$

حيث $p = 1, 2, 3, \dots$

يشير التكرار p هنا إلى رقم التدريب p th الممثل إلى perceptron

إذا كان الخطأ $e(p)$ موجباً ، فنحن بحاجة إلى زيادة ناتج perceptron $Y(p)$ ، ولكن إذا كان سالباً ، فنحن بحاجة إلى تقليل $Y(p)$

The perceptron learning rule

$$w_i(p+1) = w_i(p) + \alpha \cdot x_i(p) \cdot e(p)$$

حيث $p = 1, 2, 3, \dots$ ، α هو معدل التعلم ، ثابت إيجابي أقل من وحدة

تم اقتراح قاعدة التعلم perceptron لأول مرة بواسطة Rosenblatt في عام 1960. وباستخدام هذه القاعدة يمكننا اشتقاق خوارزمية تدريب perceptron من أجل مهام التصنيف.

خطوات خوارزمية تدريب Perceptron :

الخطوة الأولى: التهيئة Initialization

عيّن الأوزان الأولية w_1, w_2, \dots, w_n وعتبة θ للأرقام العشوائية في النطاق $[-0.5, 0.5]$.

الخطوة الثانية: التنشيط Activation

قم بتنشيط المستشعر Perceptron عن طريق تطبيق المدخلات $x_1(p), x_2(p), \dots, x_n(p)$ والخرج المطلوب $Y_d(p)$. احسب الناتج الفعلي عند التكرار $p = 1$

$$Y(p) = \text{step} \left[\sum_{i=1}^n x_i(p) w_i(p) - \theta \right]$$

حيث n هو عدد مدخلات الإدراك الحسي Perceptron ،

ودالة الخطوة Step هي دالة التنشيط Activation function.

الخطوة الثالثة: تدريب الوزن Weight training

قم بتحديث أوزان ال Perceptron

$$w_i(p+1) = w_i(p) + \Delta w_i(p)$$

حيث $\Delta w_i(p)$ هو تصحيح الوزن عند التكرار p .

يتم حساب تصحيح الوزن بواسطة دلتا

$$\Delta w_i(p) = \alpha \cdot x_i(p) \cdot e(p)$$

الخطوة 4: التكرار Iteration


قم بزيادة التكرار p بمقدار واحد ، عد إلى الخطوة 2 وكرر العملية حتى التقارب اي تقارب الخرج المرغوب مع الخرج الحقيقي.

مثال لتعلم الإدراك الحسي perceptron learning : العملية المنطقية AND

Epoch	Inputs		Desired output Y_d	Initial weights		Actual output Y	Error e	Final weights	
	x_1	x_2		w_1	w_2			w_1	w_2
1	0	0	0	0.3	-0.1	0	0	0.3	-0.1
	0	1	0	0.3	-0.1	0	0	0.3	-0.1
	1	0	0	0.3	-0.1	1	-1	0.2	-0.1
	1	1	1	0.2	-0.1	0	1	0.3	0.0
2	0	0	0	0.3	0.0	0	0	0.3	0.0
	0	1	0	0.3	0.0	0	0	0.3	0.0
	1	0	0	0.3	0.0	1	-1	0.2	0.0
	1	1	1	0.2	0.0	1	0	0.2	0.0
3	0	0	0	0.2	0.0	0	0	0.2	0.0
	0	1	0	0.2	0.0	0	0	0.2	0.0
	1	0	0	0.2	0.0	1	-1	0.1	0.0
	1	1	1	0.1	0.0	0	1	0.2	0.1
4	0	0	0	0.2	0.1	0	0	0.2	0.1
	0	1	0	0.2	0.1	0	0	0.2	0.1
	1	0	0	0.2	0.1	1	-1	0.1	0.1
	1	1	1	0.1	0.1	1	0	0.1	0.1
5	0	0	0	0.1	0.1	0	0	0.1	0.1
	0	1	0	0.1	0.1	0	0	0.1	0.1
	1	0	0	0.1	0.1	0	0	0.1	0.1
	1	1	1	0.1	0.1	1	0	0.1	0.1

Threshold: $\theta = 0.2$; learning rate: $\alpha = 0.1$

Two-dimensional plots of basic logical operations-



يمكن للمُدرِّك **perceptron** معرفة العمليات AND و OR ، ولكن ليس XOR


الشبكات العصبونية متعددة الطبقات Multilayer neural networks

■ الإدراك الحسي multilayer perceptron متعدد الطبقات عبارة عن شبكة عصبونية تلقائية تحتوي على طبقة مخفية hidden layer واحدة أو أكثر.

■ تتكون الشبكة من طبقة إدخال من الخلايا العصبونية المصدر source neurons ، وطبقة واحدة على الأقل وسطى أو مخفية من الخلايا العصبونية الحسابية computational neurons ، وطبقة ناتجة من الخلايا العصبونية الحسابية.

■ تنتشر إشارات الإدخال في اتجاه أمامي على أساس طبقة تلو الأخرى.

Multilayer perceptron with two hidden layers:



ماذا تخفي الطبقة الوسطى؟ What does the middle layer hide?

■ طبقة مخفية "تخفي" الناتج المطلوب.

لا يمكن ملاحظة الخلايا العصبية في الطبقة المخفية من خلال سلوك الإدخال / الإخراج للشبكة.

لا توجد طريقة واضحة لمعرفة الخرج المطلوب للطبقة المخفية.

■ تتضمن شبكات ANN التجارية ثلاث طبقات وأحياناً أربع طبقات ، بما في ذلك طبقة أو طبقتان مخفيتان. يمكن أن تحتوي كل طبقة من 10 إلى 1000 خلية عصبية. قد تحتوي الشبكات العصبية التجريبية على خمس أو حتى ست طبقات ، بما في ذلك ثلاث أو أربع طبقات مخفية ، وتستخدم ملايين الخلايا العصبية.

الشبكة العصبية ذات الانتشار العكسي Back-propagation neural network

■ يستمر التعلم في شبكة متعددة الطبقات بنفس الطريقة المتبعة مع المستدرك perceptron .

■ يتم تقديم مجموعة تدريبية من أنماط الإدخال إلى الشبكة.

■ تحسب الشبكة نمط الإخراج الخاص بها ، وإذا كان هناك خطأ - أو بعبارة أخرى ، فرق بين أنماط الإخراج الفعلية والمطلوبة - يتم ضبط الأوزان لتقليل هذا الخطأ.

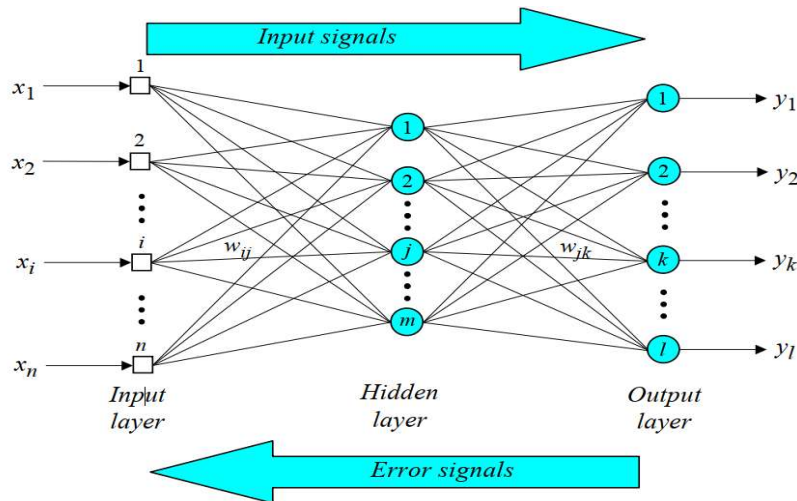
■ في الشبكة العصبية ذات الانتشار العكسي ، تتكون خوارزمية التعلم من مرحلتين.

■ أولاً ، يتم تقديم نمط إدخال التدريب إلى طبقة إدخال الشبكة. تقوم الشبكة بنشر نمط الإدخال من طبقة إلى أخرى حتى يتم إنشاء نمط الخرج بواسطة طبقة الخرج.

■ إذا كان هذا النمط مختلفاً عن الناتج المطلوب ، فسيتم حساب الخطأ ثم نشره عكسياً عبر الشبكة من طبقة الخرج إلى طبقة الإدخال. يتم تعديل الأوزان عند نشر الخطأ.

Three-layer back-propagation neural network

شبكة عصبية ثلاثية الطبقات ذات انتشار عكسي



خوارزمية تدريب الانتشار العكسي The back-propagation training algorithm

الخطوة 1: التهيئة

قم بتعيين جميع الأوزان ومستويات العتبة للشبكة على أرقام عشوائية موزعة بشكل موحد داخل نطاق صغير:

$$\left(-\frac{2.4}{F_i}, +\frac{2.4}{F_i} \right)$$

حيث F_i هو العدد الإجمالي لمدخلات العصبون i في الشبكة. تتم تهيئة الوزن على أساس كل خلية عصبية.

الخطوة 2: التنشيط

قم بتنشيط الشبكة العصبية ذات الانتشار الخلفي من خلال تطبيق المدخلات $x_1(p)$ و $x_2(p)$ و ... و x_n و $y_{d,1}(p)$ و $y_{d,2}(p)$ و ... و $y_{d,n}(p)$.
(أ) احسب المخرجات الفعلية للخلايا العصبية في الطبقة المخفية:

$$y_j(p) = \text{sigmoid} \left[\sum_{i=1}^n x_i(p) \cdot w_{ij}(p) - \theta_j \right]$$

حيث n هو عدد مدخلات العصبون j في الطبقة المخفية، و sigmoid هو دالة التنشيط sigmoid .activation function

(ب) احسب المخرجات الفعلية للخلايا العصبية في طبقة الخرج:

$$y_k(p) = \text{sigmoid} \left[\sum_{j=1}^m x_{jk}(p) \cdot w_{jk}(p) - \theta_k \right]$$

حيث m هو عدد مدخلات الخلايا العصبية k في طبقة الخرج.

الخطوة الثالثة: تدريب الوزن

قم بتحديث الأوزان في شبكة الانتشار العكسي التي تنتشر للخلف للأخطاء المرتبطة بالخلايا العصبية.

(أ) احسب تدرج الخطأ error gradient للخلايا العصبية في طبقة الإخراج:

$$\delta_k(p) = y_k(p) \cdot [1 - y_k(p)] \cdot e_k(p)$$

where $e_k(p) = y_{d,k}(p) - y_k(p)$ احسب تصحيحات الوزن:

قم بتحديث الأوزان في الخلايا: $\Delta w_{jk}(p) = \alpha \cdot y_j(p) \cdot \delta_k(p)$

$$w_{jk}(p+1) = w_{jk}(p) + \Delta w_{jk}(p)$$

(ب) احسب تدرج الخطأ للخلايا العصبية في الطبقة المخفية:

$$\delta_j(p) = y_j(p) \cdot [1 - y_j(p)] \cdot \sum_{k=1}^l \delta_k(p) w_{jk}(p)$$

احسب تصحيحات الوزن:

$$\Delta w_{ij}(p) = \alpha \cdot x_i(p) \cdot \delta_j(p)$$

تحديث الأوزان في الخلايا العصبية المخفية:

$$w_{ij}(p+1) = w_{ij}(p) + \Delta w_{ij}(p)$$


الخطوة 4: التكرار Iteration

قم بزيادة التكرار p واحدا تلو الآخر ، ثم عد إلى الخطوة 2 وكرر العملية حتى يتم استيفاء معيار الخطأ المحدد.

على سبيل المثال ، قد ننظر في شبكة الانتشار الخلفي ثلاثية الطبقات. افترض أن الشبكة مطلوبة لإجراء عملية منطقية Exclusive-OR(XOR). تذكر أن الإدراك أحادي الطبقة single-layer perception لا يمكنه القيام بهذه العملية. الآن سنقوم بتطبيق الشبكة ثلاثية الطبقات three-layer net.

شبكة ثلاثية الطبقات لحل عملية Exclusive-OR(XOR):

Three-layer network for solving the Exclusive-OR operation:



■ يتم تمثيل تأثير العتبة المطبقة على الخلايا العصبية في الطبقة المخفية أو المخرجة بوزنها ، θ ، المتصل بمدخل ثابت يساوي -1.

■ يتم تعيين الأوزان الأولية ومستويات العتبة بشكل عشوائي على النحو التالي:

$$w_{13} = 0.5, w_{14} = 0.9, w_{23} = 0.4, w_{24} = 1.0, w_{35} = -1.2, w_{45} = 1.1, \theta_3 = 0.8,$$

$$\theta_4 = -0.1 \text{ and } \theta_5 = 0.3.$$

■ **نحن نعتبر مجموعة تدريب حيث تكون المدخلات x_1 و x_2 مساوية لـ 1 والخرج المرغوب $y_{d,5}$ هو 0.**
المخرجات الفعلية للخلايا العصبية 3 و 4 في الطبقة المخفية يتم حسابها على النحو التالي:

$$y_3 = \text{sigmoid}(x_1 w_{13} + x_2 w_{23} - \theta_3) = 1 / [1 + e^{-(1 \cdot 0.5 + 1 \cdot 0.4 - 0.8)}] = 0.5250$$

$$y_4 = \text{sigmoid}(x_1 w_{14} + x_2 w_{24} - \theta_4) = 1 / [1 + e^{-(1 \cdot 0.9 + 1 \cdot 1.0 + 0.1)}] = 0.8808$$

■ الآن يتم تحديد الخرج الفعلي للخلاية العصبية 5 في طبقة الخرج على النحو التالي:

$$y_5 = \text{sigmoid}(y_3 w_{35} + y_4 w_{45} - \theta_5) = 1 / [1 + e^{-(0.5250 \cdot 1.2 + 0.8808 \cdot 1.1 - 0.3)}] = 0.5097$$

■ وبالتالي ، تم الحصول على الخطأ التالي:

$$e = y_{d,5} - y_5 = 0 - 0.5097 = -0.5097$$

■ الخطوة التالية هي تدريب الوزن. لتحديث الأوزان ومستويات العتبة في شبكتنا ، ننشر الخطأ ، e ، من طبقة المخرجات للخلف إلى طبقة الإدخال.

■ أولاً ، نحسب تدرج الخطأ error gradient للخلايا العصبية 5 في الطبقة الناتجة:

$$\delta_5 = y_5 (1 - y_5) e = 0.5097 \cdot (1 - 0.5097) \cdot (-0.5097) = -0.1274$$

■ ثم نحدد تصحيحات الوزن بافتراض أن معامل معدل التعلم α يساوي 0.1:

$$\Delta w_{35} = \alpha \cdot y_3 \cdot \delta_5 = 0.1 \cdot 0.5250 \cdot (-0.1274) = -0.0067$$

$$\Delta w_{45} = \alpha \cdot y_4 \cdot \delta_5 = 0.1 \cdot 0.8808 \cdot (-0.1274) = -0.0112$$

$$\Delta \theta_5 = \alpha \cdot (-1) \cdot \delta_5 = 0.1 \cdot (-1) \cdot (-0.1274) = -0.0127$$

■ بعد ذلك نحسب تدرجات الخطأ للخلايا العصبية 3 و 4 في الطبقة المخفية:

$$\delta_3 = y_3 (1 - y_3) \cdot \delta_5 \cdot w_{35} = 0.5250 \cdot (1 - 0.5250) \cdot (-0.1274) \cdot (-1.2) = 0.0381$$

$$\delta_4 = y_4 (1 - y_4) \cdot \delta_5 \cdot w_{45} = 0.8808 \cdot (1 - 0.8808) \cdot (-0.1274) \cdot 1.1 = -0.0147$$

■ ثم نحدد تصحيح الوزن:


$$\begin{aligned}\Delta w_{13} &= \alpha \cdot x_1 \cdot \delta_3 = 0.1 \cdot 1 \cdot 0.0381 = 0.0038 \\ \Delta w_{23} &= \alpha \cdot x_2 \cdot \delta_3 = 0.1 \cdot 1 \cdot 0.0381 = 0.0038 \\ \Delta \theta_3 &= \alpha \cdot (-1) \cdot \delta_3 = 0.1 \cdot (-1) \cdot 0.0381 = -0.0038 \\ \Delta w_{14} &= \alpha \cdot x_1 \cdot \delta_4 = 0.1 \cdot 1 \cdot (-0.0147) = -0.0015 \\ \Delta w_{24} &= \alpha \cdot x_2 \cdot \delta_4 = 0.1 \cdot 1 \cdot (-0.0147) = -0.0015 \\ \Delta \theta_4 &= \alpha \cdot (-1) \cdot \delta_4 = 0.1 \cdot (-1) \cdot (-0.0147) = 0.0015\end{aligned}$$

■ أخيرًا ، نقوم بتحديث جميع الأوزان والعتبة:

$$\begin{aligned}w_{13} &= w_{13} + \Delta w_{13} = 0.5 + 0.0038 = 0.5038 \\ w_{14} &= w_{14} + \Delta w_{14} = 0.9 - 0.0015 = 0.8985 \\ w_{23} &= w_{23} + \Delta w_{23} = 0.4 + 0.0038 = 0.4038 \\ w_{24} &= w_{24} + \Delta w_{24} = 1.0 - 0.0015 = 0.9985 \\ w_{35} &= w_{35} + \Delta w_{35} = -1.2 - 0.0067 = -1.2067 \\ w_{45} &= w_{45} + \Delta w_{45} = 1.1 - 0.0112 = 1.0888 \\ \theta_3 &= \theta_3 + \Delta \theta_3 = 0.8 - 0.0038 = 0.7962 \\ \theta_4 &= \theta_4 + \Delta \theta_4 = -0.1 + 0.0015 = -0.0985 \\ \theta_5 &= \theta_5 + \Delta \theta_5 = 0.3 + 0.0127 = 0.3127\end{aligned}$$

■ تتكرر عملية التدريب حتى يصبح مجموع تربيع الأخطاء أقل من 0.001.

منحنى التعلم للعملية Exclusive-OR (XOR):

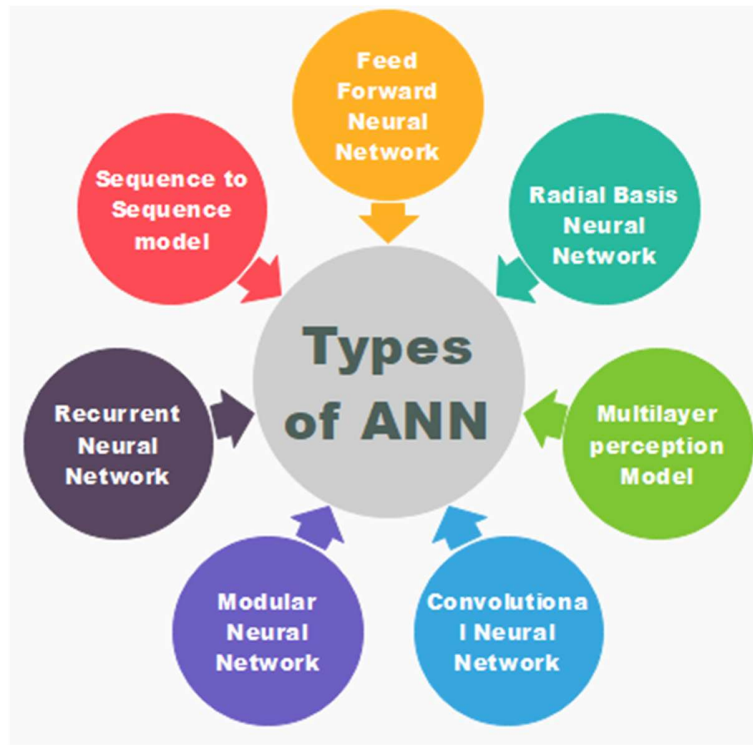


النتائج النهائية للتعليم الشبكي ثلاثي الطبقات:

Inputs		Desired output	Actual output	Error	Sum of squared errors
x_1	x_2	y_d	y_5	e	
1	1	0	0.0155	-0.0155	0.0010
0	1	1	0.9849	0.0151	
1	0	1	0.9849	0.0151	
0	0	0	0.0175	-0.0175	

أنواع الشبكات العصبونية:


تعمل الشبكة العصبونية بنفس وظائف الجهاز العصبي البشري. هناك عدة أنواع من الشبكات العصبونية يعتمد تنفيذ هذه الشبكات على مجموعة الوسائط والعمليات الحسابية المطلوبة لتحديد المخرجات.



1- Feedforward Neural Network

شبكة عصبونية Feedforward

FNN هو أنقى أشكال ANN حيث تنتقل المدخلات والبيانات في اتجاه واحد فقط. تتدفق البيانات في الاتجاه الأمامي فقط ؛ لهذا السبب تُعرف باسم شبكة التغذية الأمامية العصبونية. تمر البيانات عبر عقد الإدخال وتخرج من عقد الإخراج. العقد غير متصلة بشكل دوري. لا تحتاج إلى طبقة مخفية. في FNN ، لا داعي لوجود طبقات متعددة. قد تحتوي أيضًا على طبقة واحدة.



لها موجة انتشار أمامية يتم تحقيقها باستخدام وظيفة تنشيط التصنيف. جميع أنواع الشبكات العصبونية الأخرى تستخدم backpropagation ، لكن FNN لا تستطيع ذلك. في FNN ، يتم حساب مجموع مدخلات المنتج ووزنه ، ثم يتم تغذيته بالمخرجات.

Radial basis function Neural Network

يُجد RBFNN مسافة النقطة إلى المركز. هناك طبقتان في الشبكة العصبونية RBF. في الطبقة الداخلية ، يتم دمج الميزات مع وظيفة الأساس الشعاعي..


Radial Function= $\Phi(r) = \exp(-r^2 / 2\sigma^2)$ حيث $\sigma > 0$

تُستخدم هذه الشبكة العصبونية في نظام استعادة الطاقة. في العصر الحالي ، حيث أن نظام الطاقة ازداد من حيث الحجم والتعقيد. كلا العاملين يزيدان من مخاطر انقطاع التيار الكهربائي. يجب استعادة الطاقة بأسرع ما يمكن وبصورة موثوقة بعد انقطاع التيار الكهربائي.

Multilayer Perceptron

يحتوي المدرك متعدد الطبقات على ثلاث طبقات أو أكثر. يتم تصنيف البيانات التي لا يمكن فصلها خطيًا بمساعدة هذه الشبكة. هذه الشبكة عبارة عن شبكة متصلة بالكامل مما يعني أن كل عقدة فردية متصلة بجميع العقد الأخرى الموجودة في الطبقة التالية. يتم استخدام وظيفة التنشيط غير الخطية في Perceptron متعدد الطبقات. ترتبط عُقد طبقة الإدخال والإخراج كرسم بياني موجه. إنها طريقة تعلم عميقة بحيث تستخدم backpropagation لتدريب الشبكة. يتم تطبيقه على نطاق واسع في تقنيات التعرف على الكلام والترجمة

الآلية .




Recurrent Neural Network (RNN)

تعتمد الشبكة العصبية المتكررة على التنبؤ. في هذه الشبكة العصبية ، يتم حفظ إخراج طبقة معينة وإعادتها إلى المدخلات. وهذا يساعد على التنبؤ بنتيجة الطبقة. في الشبكة العصبية المتكررة ، تتشكل الطبقة الأولى بنفس طريقة طبقة FNN ، وفي الطبقة اللاحقة ، تبدأ عملية الشبكة العصبية المتكررة .

كل من المدخلات والمخرجات مستقلة عن بعضها البعض ، ولكن في بعض الحالات ، يتطلب الأمر التنبؤ بالكلمة التالية من الجملة.

(RNN هي نوع من الشبكات العصبية الاصطناعية المستخدمة بشكل أساسي في التعرف على الكلام ومعالجة اللغة الطبيعية (NLP). يستخدم RNN في التعلم العميق وفي تطوير النماذج التي تحاكي نشاط الخلايا العصبية في الدماغ البشري .



Modular Neural Network

في الشبكة العصبية المعيارية ، تكون عدة شبكات مختلفة مستقلة وظيفيًا. في MNN ، تنقسم المهمة إلى مهمة فرعية وتؤديها عدة أنظمة. أثناء العملية الحسابية ، لا تتصل الشبكات ببعضها البعض مباشرة. تعمل جميع الواجهات بشكل مستقل من أجل تحقيق المخرجات. الشبكات المدمجة أقوى من الشبكات المسطحة وغير المقيدة. يأخذ الوسيط إنتاج كل نظام ومعالجته لإنتاج الناتج النهائي.

Sequence to Sequence Network

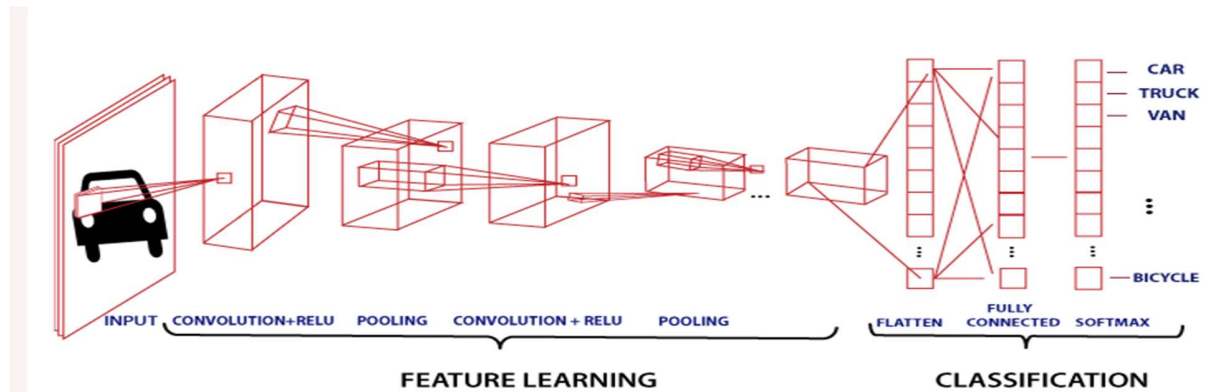
وهي تتكون من شبكتين عصبيتين متكررتين. هنا ، يعالج المشفر encoder المدخلات ، وفك التشفير decoder يعالج الإخراج. يمكن أن يستخدم المشفر ومفك التشفير إما لمعلمة واحدة أو مختلفة. يتم تطبيق نماذج التسلسل إلى التسلسل في روبوتات المحادثة والترجمة الآلية وأنظمة الإجابة على الأسئلة.

Convolutional Neural Network

الشبكة العصبية التلافيفية تستخدم في تصنيف الصور والتعرف على الصور ، تلعب الشبكة العصبية التلافيفية دورًا حيويًا في التعرف على الوجوه ، واكتشاف الأشياء ، وما إلى ذلك ، وهي بعض المجالات التي تستخدم فيها شبكة CNN على نطاق واسع. إنه مشابه لـ FNN ، تتوفر الأوزان والتحيزات القابلة للتعليم في الخلايا العصبية. تأخذ CNN صورة كمدخلات يتم تصنيفها ومعالجتها تحت فئة معينة مثل كلب ، قطة ، أسد ، نمر ، إلخ. كما نعلم ، يرى الكمبيوتر الصورة على هيئة بكسل ويعتمد على دقة الصورة. بناءً على دقة الصورة ، سترى $h * w * d$ ، حيث

$h = \text{height}$ $w = \text{width}$ and $d = \text{dimension}$

. على سبيل المثال ، ستمر كل صورة إدخال عبر سلسلة من طبقات الالتفاف جنبًا إلى جنب مع طبقات مجمعة متصلة بالكامل ومرشحات (تُعرف أيضًا باسم kernels)



Learning Techniques in Neural Networks

- Supervised Learning- "Train me!"
- Unsupervised Learning- "I am self-sufficient in learning!"
- Reinforcement Learning- "My life my rules (Hit and Trial)!"


التعلم الخاضع للإشراف: التعلم الخاضع للإشراف هو نوع من التعلم الآلي ، حيث يمكننا اعتبار أن المعلم يوجه عملية التعلم .مجموعة البيانات التي لدينا ستعمل كمدرس وستستخدم لتدريب النموذج والآلات .بمجرد تدريب النموذج ، يبدأ في اتخاذ القرار أو التنبؤ عند تقديم بيانات جديدة إليه .
يمكن تقسيمها إلى نوعين:

Classification

إنها تقنية تهدف إلى إعادة إنتاج مهام الفصل ، ويتم تقسيم البيانات إلى "فئات" .مثال: التعرف على نوع السيارة في الصورة


Regression

تراجع الانحدار هو أسلوب يهدف إلى إنتاج قيمة الخرج .مثال: يمكننا استخدامه للتنبؤ بسعر منتج مختلف .



التعليم غير الخاضع للإشراف: يُستخدم خوارزمية التعلم الآلي غير الخاضعة للإشراف عندما لا يتم تصنيف المعلومات .إذا يتم تزويد النموذج بمجموعة بيانات ، فإنه يبحث تلقائيًا عن أنماط وعلاقات في مجموعة البيانات عن طريق إنشاء مجموعات فيها .

لنفترض أننا قدمنا صورًا من التفاح والموز والمانجو إلى النموذج ، بناءً على بعض الأنماط والعلاقات التي ينشئها يقسم مجموعة البيانات إلى أصناف .الآن إذا تم تسليم بيانات جديدة إلى النموذج ، فإنها تضيفها إلى إحدى الأصناف التي تم إنشاؤها.



كما أن لها نوعان:

Clustering

يستخدم التجميع لإيجاد التشابه والاختلاف في شيء معين. إنها تجمع أشياء متشابهة. يمكن أن تساعدنا هذه الخوارزمية في حل العديد من العقبات. مثال ابحت عن مجموعة من الصور بسيارات متشابهة ، أو حدد نوعًا مختلفًا من الأخبار.

Association

وهي طريقة لتتقرب عن البيانات غير الخاضعة للرقابة ، بعد التجميع ، والتي تجد ارتباطات مثيرة للاهتمام (العلاقات ، التبعيات) في مجموعة كبيرة من عناصر البيانات

التعلم شبه الخاضع للإشراف: يقع في مكان ما بين التعلم الخاضع للإشراف والتعلم غير الخاضع للإشراف. لذلك ، يستخدمون كلاً من البيانات المصنفة وغير المسممة للتدريب حيث يتم استخدام كمية صغيرة من البيانات المصنفة وكمية كبيرة من البيانات غير المسممة بشكل عام ، يتم اختيار التعلم شبه الخاضع للإشراف عندما تتطلب البيانات المسمى المكتسبة موارد ماهرة وهامة لتدريبها.

التعلم المعزز: هو قدرة الوكيل على التفاعل مع البيئة ومعرفة أفضل النتائج. إنه يحقق مفهوم طريقة الضرب والتجربة. يُكافأ الوكيل أو يُدان بنقطة مقابل إجابة صحيحة أو خاطئة ، وبناءً على نقاط المكافآت الإيجابية التي اكتسبها النموذج المدرب نفسه يتخذ القرار. وبالتالي تدربت على التنبؤ بالبيانات الجديدة المقدمة لها.

What are the Applications of Neural Networks?

Application	Architecture / Algorithm	Activation Function
	البنية / الخوارزمية	

Process modeling and control نمذجة العملية والتحكم فيها	Radial Basis Network	Radial Basis
Machine Diagnostics تشخيصات الجهاز	Multilayer Perceptron	Tan- Sigmoid Function
Portfolio Management إدارة المحافظ	Classification Supervised Algorithm	Tan- Sigmoid Function
Target Recognition التعرف على الهدف	Modular Neural Network	Tan- Sigmoid Function
Medical Diagnosis تشخيص طبي	Multilayer Perceptron	Tan- Sigmoid Function
Credit Rating التصنيف الائتماني	Logistic Discriminant Analysis with ANN, Support Vector Machine	Logistic function
Targeted Marketing التسويق المستهدف	Back Propagation Algorithm	Logistic function
Voice recognition التعرف على الصوت	Multilayer Perceptron, Deep Neural Networks(Convolutional Neural Networks)	Logistic function
Financial Forecasting التنبؤ المالي	Backpropagation Algorithm	Logistic function
Intelligent searching البحث الذكي	Deep Neural Network	Logistic function
Fraud detection الكشف عن الغش	Gradient – Descent Algorithm and Least Mean Square (LMS) algorithm.	Logistic function